张乐骏　Lejun Zhang

LLM Multi-Agent Systems · AI Safety · Multimodal LLM · Efficient LLM

+86 173-1730-3177 | lejunzhang@sjtu.edu.cn | Webpage | GitHub | Google Scholar

教育背景

上海交通大学 Shanghai Jiao Tong University **2026.4 – 至今**

纽约大学 New York University **2024.9 – 2025.12**

上海师范大学 Shanghai Normal University **2020.9 – 2024.6**

论文

在投 / Under Review

WolfSociety: How Harmful-Agent Scaling Drives Collective Collapse in Financial Agent Societies AAAI 2027 · CCF-A
L. Zhang, S. Lu-Liang, X. Jiang, M. Wen, W. Zhang, S. Gu

已发表

TennisTV: Do Multimodal Large Language Models Understand Tennis Rallies? ICASSP 2025 · Oral · CCF-B
Z. Bao*, L. Zhang*

Efficient LLM Training by Accelerating Gradient Low-Rank Projection and Adaptive Subspace Switching ICASSP 2025 · CCF-B
T. Miao*, L. Zhang*, Z. Bao*

科研与项目经历

多智能体系统安全与群体失效研究 Harmful-Agent Scaling in LLM Agent Societies AAAI 2027 在投

- **问题定义：**研究 LLM 多智能体社会中有害智能体的规模效应，刻画少量有害个体如何经交互反馈触发系统级集体失效。
- **方法设计：**提出 Agent Society Dynamics 有限规模分析框架，搭建信息传播、智能体决策与市场反馈三者耦合的仿真社会，系统扫描有害占比、社会规模与交互结构对失效边界的影响。
- **核心结论：**发现显著的非线性、规模依赖崩塌转变——社会规模由 **100** 增至 **2000** 时，临界有害占比由 **4.7%** 降至 **2.2%**，而临界有害数量由 **4.7** 升至 **44**；多组机制与流动性消融验证了该规律的稳健性。

TennisTV 多模态评测基准 Tennis Video Understanding Benchmark ICASSP 2025 Oral

- **工作定位：**提出 TennisTV——首个面向网球视频理解的多模态大模型评测基准，填补细粒度体育视频评测空白。
- **数据构建：**首次将网球视频拆分为回合事件与击球事件两级粒度，设计自动化标注流水线，产出覆盖 **9 类任务**、**2943 条**人工校验问答的数据集。
- **评测分析：**系统评测 **17 个**主流 MLLMs（开源/闭源 × thinking/non-thinking），定位模型在时序定位与细粒度动作理解上的共性短板。

大模型内存高效训练 Memory-Efficient LLM Training ICASSP 2025

- **研究目标：**聚焦大模型内存高效微调，对比 Zeroth-order Optimization 与 Low-Rank Projection 两条技术路线。
- **方法改进：**复现 MeZO、GaLore、AdaRank；针对 GaLore 中低秩梯度分解的性能瓶颈，基于 Randomized-SVD 提出加速分解方法与自适应子空间切换策略。
- **实验结果：**在下游任务精度不降的前提下，训练时间效率提升 **20%**，峰值显存占用降低 **40%**。

Kaggle 竞赛 · 银牌 MAP — Charting Student Math Misunderstandings

- **任务背景：**面向 **65 类** Misconception 标签的学生数学误解多分类识别，类别高度不均衡。
- **建模方案：**构建 Gemma-2 9B、Qwen3-8B、DeepSeek-Math-7B 三模型集成系统，采用概率级融合提升鲁棒性；以 LoRA（PEFT）微调 Gemma-2 9B，并适配 Kaggle 的 GPU 与时长限制。
- **工程结果：**实现多 GPU 并行推理，将推理验证耗时压缩至 **2 小时**以内，最终斩获竞赛**银牌**。

扩散模型个性化图像编辑 Diffusion-based Personalized Image Editing

- **算法复现：**基于开源实现复现 Textual Inversion 与 InstructPix2Pix，梳理文本反演与指令式编辑两类范式的能力边界。
- **方法探索：**面向个性化编辑场景，设计一次性上下文提示模板，在不额外训练的前提下提升编辑结果的一致性与可控性。

实习经历

商汤科技 SenseTime 视觉算法实习生 **2023.7 – 2023.10**

- **模型选型：**在政府合作电网巡检项目（绝缘子破损、电线绑扎不规范、导线裸露等场景）中，评测 R-CNN 系列、RetinaNet、CenterNet 等主流检测器，输出选型结论与误检归因分析；最终选型方案在自建测试集上取得 **mAP@0.5 = 0.68**，较初始 baseline 提升 **4.2** 个点。
- **数据建设：**主导超 **8000 张**图像的目标检测标注，制定标注规范并建立质量回流机制，交付高质量训练集。
- **工程沉淀：**维护实验日志与技术文档，跟踪目标检测方向顶会进展并输出调研报告。

技术栈：PyTorch，开源项目本地化部署，Linux

技能与荣誉

- **编程与框架：**Python，PyTorch，Hugging Face Transformers / PEFT，LangGraph，Django。
- **研究技能：**大模型微调（LoRA / 全参）、多 GPU 分布式训练与推理、评测基准构建与自动化标注流水线、多智能体系统仿真。
- **工具与环境：**Linux，Docker，Git，LaTeX，Cursor / Codex。
- **竞赛与荣誉：**Kaggle MAP 竞赛银牌；MCM 数学建模竞赛 Finalist 提名（全球前 **1.98%**）；全国大学生创新创业大赛国家级立项。
- **语言能力：**中文（母语），英语（流利）。